有理関数近似を用いた効率的な逆関数法の実現と準モンテカルロ法への応用

Efficient Inverse Transform Sampling via Rational Interpolation and Its Application to Quasi-Monte Carlo Methods

鴛尾 直樹, 石谷 謙介, 黒澤 哲生, 寒川 蒼, 植山 蓮太朗　　東京都立大学大学院理学研究科数理科学専攻
okinaoki24@gmail.com

1. 目的

本講演では、

- **逆関数法に必要な累積分布関数(CDF)の逆関数(逆CDF)の近似モデルを構築する手続きを新たに提案する.**
- **構築した近似モデルを用いて実際に乱数を発生させた結果を示す.**
- **準モンテカルロ法(QMC)へ適用した結果を示す.**

2. 背景

- **準モンテカルロ法(QMC)は，大量の乱数を利用する金融シミュレーションにおいて有用**
- **逆関数法は，準乱数列の性質を保存するため，QMCとの相性が良いことが知られている**
- **しかし，逆関数法に必要な逆CDFは解析解を得られない場合が多く，その場合に逆関数法を実行するには反復法的な数値計算を用いる必要があり，計算コストが大きい**

→ 逆関数法のQMCへの応用を見据え，逆CDFを高速/高精度な近似モデルを構築したい

3. 逆関数法

定理

Uを一様分布 $U(0,1)$ に従う確率変数とし， $F_X(x)$ を確率変数 X の CDF とする. このとき，確率変数 $F_X^{-1}(U)$はXと同じ分布に従う.

2変数の場合

$$U = u \xrightarrow{F_X^{-1}} X = x = F_X^{-1}(u)$$

$$V = v \xrightarrow{F_{Y|X=x}^{-1}} Y = y = F_{Y|X=x}^{-1}(v)$$

逆関数法の重要性

- **決定論的な写像(逆CDF)により乱数生成が可能**
  → 準モンテカルロ法 (QMC) , 分散減少法と相性が良い (※棄却法では難しい)
- **コピュラの乱数生成にも使われる**

4. 近似手法

Floater-Hormann法 [1] (FH法):
極を持たない重心形式 [2] の有理関数補間手法

$$f(x_1,\cdots,x_N) \simeq r_d(x_1,\cdots,x_N)$$

$$r_d(x_1,\cdots,x_N) := \sum_{i_1=1}^{n_1}\cdots\sum_{i_N=1}^{n_N} f(x_1^{[i_1]},\cdots,x_N^{[i_N]}) \prod_{j=1}^{N} \frac{\frac{w_j^{[i_j]}}{x_j - x_j^{[i_j]}}}{\sum_{k=1}^{n_j} \frac{w_j^{[k]}}{x_j - x_j^{[k]}}}$$

$$w_s^{[k]} := (-1)^{k-d_s} \sum_{i=\max(k-d_s,0)}^{\min(k,n-d_s)} \prod_{\substack{j=i \\ j\neq k}}^{i+d_s} \frac{1}{\left|x_s^{[k]} - x_s^{[j]}\right|}, \quad \begin{matrix} s = 1,\dots,N \\ k = 1,\dots,n_s \end{matrix}$$

補間条件: $f(x_1^{[i_1]},\cdots,x_N^{[i_N]}) = r_d(x_1^{[i_1]},\cdots,x_N^{[i_N]})$

FH法の位置付け

- 多項式近似
- 有理関数近似 ← 多項式より表現力が豊か
  $f(x) \simeq R(x) = P(x)/Q(x)$
  - 局所近似 ← 1点付近でしか近似できない
  - 補間法 ← 大域的な近似が可能
    補間条件: $f(x_i) = R(x_i)$ $(\forall x_i$:補間点$)$
    - 重心形式以外 ← **「到達不能点」の問題**
    - **重心形式**
      - FH法以外 ←**「不要な極」の問題**
      - **FH法 ←到達不能点と不要な極を同時に解決**

5. 逆CDFの近似の手続き

$x = F_X^{-1}(u)$について

- **補間点$\{u^{[i]}\}_{0\le i\le n}$とブレンド次数$d$を決める**
- **$\{F_X^{-1}(u^{[i]})\}_{0\le i\le n}$を数値的に求める**
- **FH法を用いて $F_X^{-1}(u)$の近似式 $r_d(u)$を構築:**

$$F_X^{-1}(u) \simeq r_d(u) = \frac{\sum_{i=1}^{n} \frac{F_X^{-1}(u^{[i]})w^{[i]}}{u-u^{[i]}}}{\sum_{i=1}^{n} \frac{w^{[i]}}{u-u^{[i]}}}$$

$y = F_{Y|X=x}^{-1}(v)$ について

- **補間点$\{(v^{[i]},x^{[j]})\}_{0\le i\le n_1}^{0\le j\le n_2}$とブレンド次数$d=(d_1,d_2)$を決める**
- **$\{F_{Y|X=x^{[j]}}^{-1}(v^{[i]})\}_{0\le i\le n_1}^{0\le j\le n_2}$を数値的に求める**
- **FH法を用いて $F_{Y|X=x}^{-1}(v)$の近似式 $r_d(v,x)$を構築:**

$$F_{Y|X=x}^{-1}(v) \simeq r_d(v,x) = \frac{\sum_{i=1}^{n_1}\sum_{j=1}^{n_2} \frac{F_{Y|X=x^{[j]}}^{-1}(v^{[i]})w_1^{[i]}w_2^{[j]}}{(v-v^{[i]})(x-x^{[j]})}}{\sum_{i=1}^{n_1}\sum_{j=1}^{n_2} \frac{w_1^{[i]}w_2^{[j]}}{(v-v^{[i]})(x-x^{[j]})}}$$

6. 近似精度の目標

真の期待値とQMC平均値の誤差の関係

$E := \int g(x)f_X(x)dx = \int g(F^{-1}(u))du$: 真値
$E_M := \frac{1}{M}\sum_{m=1}^{M} g(F^{-1}(u_m))$: QMC平均の真値
$\hat{E}_M := \frac{1}{M}\sum_{m=1}^{M} g(r_d(u_m))$: QMC平均の近似値

$$\underbrace{\left|E-\hat{E}_M\right|}_{\text{QMC誤差の近似値}} \le \underbrace{|E-E_M|}_{\text{QMC誤差}} + \underbrace{\left|E_M-\hat{E}_M\right|}_{\text{近似誤差}}$$

Koksma-Hlawkaの不等式[4] (low-discrepancy列の場合)

$|E-E_M| \le C\frac{(\log M)^s}{M}$, s: 次元数

QMC誤差　実用上，高々$M\sim 10^7$と仮定 $(右辺) > 10^{-7}$

$\left|E_M-\hat{E}_M\right| \le L\,\|F^{-1}-r_d\|_\infty$ with $L := \sup_x|g'(x)|$

近似誤差　$g(x)$ の変化がなだらかだと仮定 (e.g.ヨーロピアン・オプションのペイオフ関数)

$(右辺) \simeq \|F^{-1}-r_d\|_\infty$

$\|F^{-1}-r_d\|_\infty \sim 10^{-7}$程度であれば，近似誤差はQMC誤差に埋もれるので，十分

7. 変数変換

- 逆 CDF が曲率の大きな点を複数持つ場合，提案手法の近似精度が顕著に低下する傾向
- そこで，逆 CDF の形状に応じて，関数変化の激しい領域を事前に特定し，適切な**変数変換$u \to s(u)$を施す**ことで，それらの領域を**引き延ばしてから**補間近似式を構築すれば，少ない補間点数で高い精度を実現できる

$$G(t) := F_X^{-1}\left(s^{-1}(t)\right) \simeq r_d(t)$$
$$\Rightarrow F_X^{-1}(u) = G\left(s(u)\right) \simeq r_d\left(s(u)\right)$$

逆CDF近似の主な先行研究

Wichura (1988) [6], Acklamなど

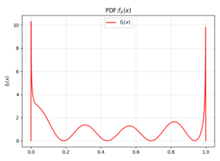
→ **標準正規分布の逆CDF$\Phi^{-1}(u)$に対して**，最良近似アルゴリズムと**有理関数補間**を用いた高速/高精度な近似式を構築

Derflinger etal. (2008) [7]

→**与えられた1変数密度関数に対応する分布**の逆CDFを，**領域分割**と**多項式補間**を用いて近似するアルゴリズムを開発
(← 多数の領域に分割するため，探索コストがかかる)

8. 逆CDF近似の例(1次元)

$$f_X(x) = \frac{1+\sin(8\pi x)}{\pi\sqrt{x(1-x)}}, 0<x<1$$

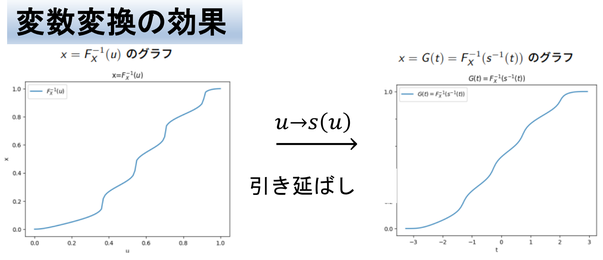


- **ターゲット**: $F_X^{-1}(u) \simeq r_d(s(u))$ $(u\in[10^{-8},1-10^{-8}])$
- **変数変換マップ** $s(u)$: 端点の特異性と内部の 4 つのピークを平滑化.

$$s(u) = \arcsin(2u-1) + 0.5\sum_{k=1}^{4}\sqrt[3]{u-u_k}$$
ただし $u_k = F_X((4k-1)/16)$

- 補間点:$\{s^{[i]}\}_{0\le i\le n} = \{\frac{i}{n}\}_{0\le i\le n}$, $n=320$
- ブレンド次数:$d=3$

変数変換の効果



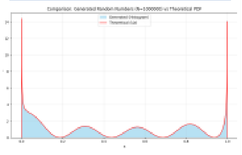
近似結果(FH法)

最大絶対誤差: $\|F_X^{-1}-r_d\|_\infty < 4.93\times10^{-8}$

近似式: (小数点以下第 3 位まで)

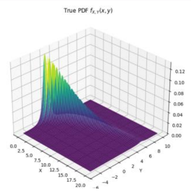
$$r_d(s) = \frac{0+\frac{0.002}{s+3.246}+\cdots+\frac{22607.533}{s-2.943}}{\frac{-22607.533}{s+3.265}+\frac{90430.133}{s+3.246}+\cdots+\frac{22607.533}{s-2.943}}$$

ヒストグラム (10^6個生成)



9. 逆CDFの近似(2次元モヒカン分布)

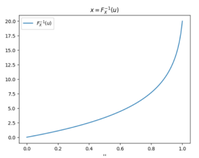
$$f_{X,Y}(x,y) = c\frac{\exp(-0.2x)}{(1+x^2+(y-\log(1+x))^2)^2}, \quad (x,y)\in[0,20]\times[-5,10]$$



- **ターゲット**: $F_X^{-1}(u) \simeq r_d(s(u))$ $(u\in[10^{-8},1-10^{-8}])$
- **変数変換マップ** $s(u)$:

$$s(u) = \log\frac{u}{1-u}$$

- 補間点:$\{s^{[i]}\}_{0\le i\le n} = \{\frac{i}{n}\}_{0\le i\le n}$, $n=70$
- ブレンド次数:$d=5$



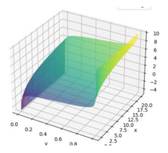
近似結果

$\|F_X^{-1}-r_d\|_\infty < 2.23\times10^{-7}$

- **ターゲット**: $F_{Y|X=x}^{-1}(v) \simeq r_d(s(v),t(x))$ $((v,x)\in[10^{-8},1-10^{-8}]\times[0,20])$
- **変数変換マップ** $s(v),t(x)$:

$$s(v) = \log\frac{v}{1-v}, \quad t(x) = \log(0.5+x)$$

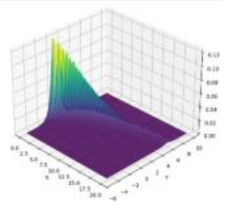
- 補間点:
  - $\{s^{[i]}\}_{0\le i\le n_1} = \{\frac{i}{n_1}\}_{0\le i\le n_1}$, $n_1=200$
  - $\{t^{[i]}\}_{0\le i\le n_2} = \{\frac{i}{n_2}\}_{0\le i\le n_2}$, $n_2=200$
- ブレンド次数:$d=(3,3)$



近似結果

$\|F_{Y|X}^{-1}-r_d\|_\infty < 2.02\times10^{-7}$

ヒストグラム (10^6個 生成)



10. 乱数生成のコスト:求根アルゴリズム vs 有理関数近似

求根アルゴリズムの使用(従来手法)

- 一様乱数 u を生成する度に，方程式 $F_X(x) = u$ を x について**数値的に求根**
- **求根アルゴリズムおよび密度関数の数値積分を実行 → 乱数生成のための計算コストがかさむ**
- n 変数の場合, **n個の条件付きCDF** に対して上記の諸計算を実行 → **計算コストが膨大に**

有理関数近似モデルの使用(提案手法)

- 構築済みの有理近似式 $r_d(\simeq F^{-1})$**は，四則演算だけで構成されている→ 高速/高精度に乱数生成可能**

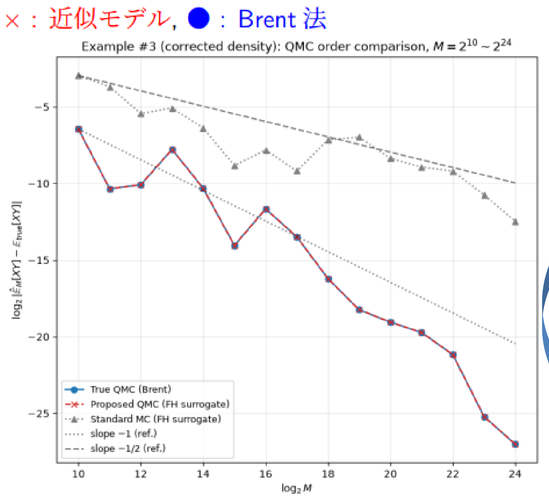
10^4個の乱数生成時間の比較

対象分布	求根	近似モデル
1 次元	582.100 秒	**0.063 秒**
モヒカン	3013.445 秒	**0.085 秒**

※精度水準は絶対誤差を 10^{-7} オーダーに統一
※求根アルゴリズムは Brent 法を使用

11. QMCの収束性の検証

×：近似モデル, ●：Brent 法



【動機】 モヒカン分布に従う確率変数 (X,Y)の期待値 $E[XY]$に焦点を当て，Scrambled Sobol'列を用いてQMC を実施：
・誤差$|E[XY]-\frac{1}{M}\sum_{m=0}^{M}x_my_m|$ を，$M = 2^{10}$ から2^{24}について評価
・提案手法がScrambled Sobol'列[5]の収束レート$O(M^{-3/2})$ ～$O(M^{-1})$ に影響を与えないことを実証したい

【結果】 **・ 収束レートは $O(M^{-1})$を上回る**
・誤差は近似モデルとBrent法とでほぼ一致 **→近似誤差が全体の誤差を阻害しない**

12. 結論

成果 1:
様々な手法を検討する中で，特にFH 法の特性に着目し，頑健な逆 CDF の近似手法を提案
成果 2:
分布形状に応じた適切な変数変換を組み込むことで，高速/高精度な近似を実現
成果 3:
近似モデル由来の誤差がQMCの収束性を阻害せず，提案手法とQMCを組み合わせることで，本来のQMCの高いパフォーマンスを引き出せることを実証

13. 今後の展望

現在の課題:
本研究では，分布形状を目視で確認し，**試行錯誤により**適切な変数変換を提案手法に組み込んでいる
今後の課題:
与えられた分布に対して，適切な変数変換を発見する手続きを，どこまで**自動化**することができるか…

参考文献

[1] Michael S. Floater and Kai Hormann. Barycentric rational interpolation with no poles and high rates of approximation. Numerische Mathematik, 2007.
[2] Kai Hormann. Barycentric Interpolation. In Gregory E. Fasshauer and Larry L. Schumaker, editors, Approximation Theory XIV: SanAntonio 2013, volume 83, pages 197–218. Springer International Publishing, Cham, 2014.
[3] Ke Jing and Ning Kang. A Convergent Family of Bivariate Floater-Hormann Rational Interpolants. Computational Methods and Function Theory, 21(2):271–296, June 2021.
[4] Niederreiter Harald. Random number generation and quasi-monte carlo methods. SIAM, 63, 01 1992
[5] Art B. Owen. Scrambled net variance for integrals of smooth functions. Ann. Statist., 25(6):1541–1562, 1997.
[6] Michael J. Wichura. Algorithm as 241: The percentage points of the normal distribution. Journal of the Royal Statistical Society. Series C (Applied Statistics), 37(3):477–484, 1988.
[7] Gerhard Derflinger, Wolfgang Hörmann, and Josef Leydold. Random variate generation by numerical inversion when only the density is known. WorkingPaper 78, 2008.